实验四:数据库与SQL语句

在实验三中,我已经爬取了ESI网站的学科数据并完成1-2题

在实验四中,我决定还是用学长提供的数据来完成3-7题

3. 将获取的数据导入到一个关系型数据库系统中(系统可以自选)

暑假我们刚学过SQL,那选择 SQL Server Management Studio 最顺手

先打开一个csv看一下,发现第1行是说明文字,第2行才是表头:

	Α	В	С	D	E	F	G	Н	1	J	K	L
1	Indicators	Results Lis	t: Institutio	ns Filter	Results By:	ResearchFi	elds Filter	Value(s):	AGRICULT	JRAL SCIEN	NCES Sho	ow: Top
2		Institution	Countries	Web of Sc	Cites	Cites/Pape	Top Papers	S				
3	1	CHINESE A	CHINA MA	15661	332254	21.22	251					
4	2	CHINESE A	CHINA MA	12222	223855	18.32	198					
5	3	UNITED S	USA	12564	220644	17.56	105					
6	4	CHINA AG	CHINA MA	10052	207779	20.67	166					
7	5	INRAE	FRANCE	9314	187838	20.17	118					
8	6	JIANGNAN	CHINA MA	8027	181325	22.59	166					
9	7	NORTHW	CHINA MA	9024	180634	20.02	162					
10	8	WAGENIN	NETHERL/	6819	172734	25.33	152					
11	9	CONSEJO	SPAIN	7656	167593	21.89	94					
12	10	NANJING	CHINA MA	6480	137921	21.28	99					
13	11	UNIVERSI	USA	6175	129479	20.97	110					
14	12	UNIVERSIT	CHINA MA	5950	127682	21.46	95					
15	13	ZHEJIANG	CHINA MA	5313	125715	23.66	148					
16	14	EGYPTIAN	EGYPT	7861	117405	14.94	103					
17	15	INDIAN C	INDIA	12753	111262	8.72	66					
18	16	SOUTH CH	CHINA MA	3524	108282	30.73	117					
19	17	CGIAR	FRANCE	5262	107193	20.37	69					
20	18	HUAZHON	CHINA MA	4855	97482	20.08	68					
21	19	UNIVERSI	BRAZIL	6169	95242	15.44	35					
22	20	JIANGSU (CHINA MA	4084	89040	21.8	176					
23	21	STATE UN	USA	5172	86527	16.73	62					
24	22	CENTRE N	FRANCE	4113	81348	19.78	60					
25	23	CORNELL	USA	3551	78744	22.18	59					

最后一行是 Copyright ?2025 Clarivate,也应该去掉:

1330	A B C	D	E	F	G	Н	1	J	K	L
1359	1356 MAE FAH THAILA		3627	15.37	2					
1360	1358 NAMIK KETURKI		3625	10.3	1					
1361	1359 GANGNEL SOUTH	1 K(268	3621	13.51	1					
1362	1360 TAMPERE FINLAN	ND 234	3619	15.47	0					
1363	1361 HOSPITAL CANAI	DA 202	3618	17.91	2					
1364	1362 BRAUNSC GERMA	AN) 188	3614	19.22	1					
1365	1362 ICAR - INI INDIA	393	3614	9.2	6					
1366	1364 HUNGARI, HUNG	ARY 180	3605	20.03	2					
1367	1365 LIAONING CHINA	M/ 333	3604	10.82	0					
1368	1366 DAIRYNZ NEW Z	ZEAI 239	3599	15.06	0					
1369	1367 SMITHSOLUSA	209	3598	17.22	0					
1370	1367 BAYER CR GERMA	AN) 250	3598	14.39	2					
1371	1369 GENERAL USA	107	3595	33.6	4					
1372	1370 STEFAN C ROMA	NIA 161	3591	22.3	5					
1373	1371 KAGOSHII JAPAN	306	3588	11.73	1					
1374	1372 UNIVERSI USA	127	3580	28.19	4					
1375	1373 HOPITAL FRANC	CE 123	3573	29.05	3					
1376	1373 HEINRICH GERMA	AN) 136	3573	26.27	4					
1377	1375 UNIVERSI SOUTH	H AF 184	3572	19.41	6					
1378	1376 BANGLAD BANGI	AD 170	3567	20.98	2					
1379	1376 NEAR EAS TURKIN	/E 204	3567	17.49	2					
1380	1378 GRIFFITH AUSTR	ALI, 205	3562	17.38	2					
1381	1378 UMM AL- SAUDI	AR, 308	3562	11.56	3					
1382	1380 SAINT LOUSA	108	3561	32.97	4					
1383	1381 VIT VELLC INDIA	144	3558	24.71	2					
	Copyright ?2025 Clarivate									
1385										

SSMS 不能直接跳过第一行和最后一行,所以我们先把每个 CSV 的第一行和最后一行删掉,再导入

在 Powershell 执行下面命令:

```
$src="D:\ESI\download"; $dst="D:\ESI\clean"; New-Item -ItemType Directory -Force -Path $dst | Out-Null
Get-ChildItem $src -Filter *.csv | ForEach-Object {
    $lines = Get-Content $_.FullNameGet-ChildItem $src -Filter *.csv
    $lines[1..($lines.Count-2)] | Set-Content -Encoding UTF8 (Join-Path $dst $_.Name)
}
```

解释一下:

- 1. src 是原始文件路径, dst 是目标文件路径
- 2. New-Item 用于创建一个新目录,如果 D:\ESI\clean 不存在,会自动创建
- 3. Get-ChildItem \$src -Filter *.csv 会列出 src 中所有扩展名为 .csv 的文件
- 4. ForEach-Object 遍历每个文件
- 5. \$lines = Get-Content \$_.FullName 会把整个文件的内容读成一个字符串数组,每一行是一个元素
- 6. \$lines[1..(\$lines.Count-2)] 是数组切片语法,表示从第二行到倒数第二行,删除文件的第一行和最后一行
- 7. Set-Content 把上一步得到的"去掉第一行的内容"写入到新的文件中

可以看到,第一行已经成功去掉了:

	Α	В	С	D	Е	F	G	Н	1	J	K	L
1		Institution	Countries	Web of Sc	Cites	Cites/Pape	Top Papers					
2	1	CHINESE A	CHINA MA	15661	332254	21.22	251					
3	2	CHINESE A	CHINA MA	12222	223855	18.32	198					
4	3	UNITED S	USA	12564	220644	17.56	105					
5	4	CHINA AG	CHINA MA	10052	207779	20.67	166					
6	5	INRAE	FRANCE	9314	187838	20.17	118					
7	6	JIANGNAN	CHINA MA	8027	181325	22.59	166					
8	7	NORTHW	CHINA MA	9024	180634	20.02	162					
9	8	WAGENIN	NETHERL/	6819	172734	25.33	152					
10	9	CONSEJO	SPAIN	7656	167593	21.89	94					
11	10	NANJING	CHINA MA	6480	137921	21.28	99					
12	11	UNIVERSIT	USA	6175	129479	20.97	110					
13	12	UNIVERSIT	CHINA MA	5950	127682	21.46	95					
14	13	ZHEJIANG	CHINA MA	5313	125715	23.66	148					
15	14	EGYPTIAN	EGYPT	7861	117405	14.94	103					
16	15	INDIAN C	INDIA	12753	111262	8.72	66					
17	16	SOUTH C	CHINA MA	3524	108282	30.73	117					
18	17	CGIAR	FRANCE	5262	107193	20.37	69					
19	18	HUAZHON	CHINA MA	4855	97482	20.08	68					
20	19	UNIVERSI	BRAZIL	6169	95242	15.44	35					
21	20	JIANGSU I	CHINA MA	4084	89040	21.8	176					
22	21	STATE UN	USA	5172	86527	16.73	62					
23	22	CENTRE N	FRANCE	4113	81348	19.78	60					
24	23	CORNELL	USA	3551	78744	22.18	59					
25	24	UNIVERSI	USA	3908	78346	20.05	64					

最后一行也成功去掉了:

1000	A B	C	D 100	E	F 20.03	G	Н	1	J	K	L
1366	1365 LIAONIN		333	3604	10.82	0					
1367	1366 DAIRYN	Z NEW ZEAI	239	3599	15.06	0					
1368	1367 SMITHS	DIUSA	209	3598	17.22	0					
1369	1367 BAYER C	R GERMAN)	250	3598	14.39	2					
1370	1369 GENERA	L USA	107	3595	33.6	4					
1371	1370 STEFAN	C ROMANIA	161	3591	22.3	5					
1372	1371 KAGOSH	III JAPAN	306	3588	11.73	1					
1373	1372 UNIVERS	SITUSA	127	3580	28.19	4					
1374	1373 HOPITAI	LIFRANCE	123	3573	29.05	3					
1375	1373 HEINRIC	H GERMAN)	136	3573	26.27	4					
1376	1375 UNIVERS	SI SOUTH AF	184	3572	19.41	6					
1377	1376 BANGLA	D BANGLAD	170	3567	20.98	2					
1378	1376 NEAR EA	AS TURKIYE	204	3567	17.49	2					
1379	1378 GRIFFITH	H AUSTRALI,	205	3562	17.38	2					
1380	1378 UMM AI	SAUDI AR	308	3562	11.56	3					
1381	1380 SAINT LO	OLUSA	108	3561	32.97	4					
1382	1381 VIT VELL	.C INDIA	144	3558	24.71	2					
1383											
1384											
1385											
1386											
1387											
1388											
1389											
1390											
1391											

批量导入所有CSV文件,每个表格的名字来源于CSV文件名,也就是学科名称:

```
# === 参数设置 ===
$folder = "D:\ESI\clean"  # 存放 CSV 文件的文件夹
$server = "localhost"  # SQL Server 实例名
                           # 目标数据库名
$database = "ESI"
# === 遍历文件夹中所有 CSV 文件并逐个导入 ===
Get-ChildItem $folder -Filter *.csv | ForEach-Object {
   $file = $_.FullName
                                                         # 当前 CSV 文件的完整路径
    $table = "staging_" + ($_.BaseName -replace '[^A-Za-Z0-9_]', '_') # 根据文件名生成表名
   $tmp = [IO.Path]::GetTempFileName()
                                                        # 创建一个临时 SQL 文件
-- 如果表不存在就创建
IF OBJECT_ID('dbo.$table') IS NULL
 CREATE TABLE dbo.$table(
  [Rank] NVARCHAR(64),
   [Institutions] NVARCHAR(512),
   [Countries/Regions] NVARCHAR(128),
   [Web of Science Documents] NVARCHAR(64),
   [Cites] NVARCHAR(64),
  [Cites/Paper] NVARCHAR(64),
   [Top Papers] NVARCHAR(64)
);
END;
-- 清空旧数据
TRUNCATE TABLE dbo.$table;
-- 从 CSV 导入数据
BULK INSERT dbo.$table
FROM '$file'
WITH (
                  -- 使用原生 CSV 解析
 FORMAT='CSV',

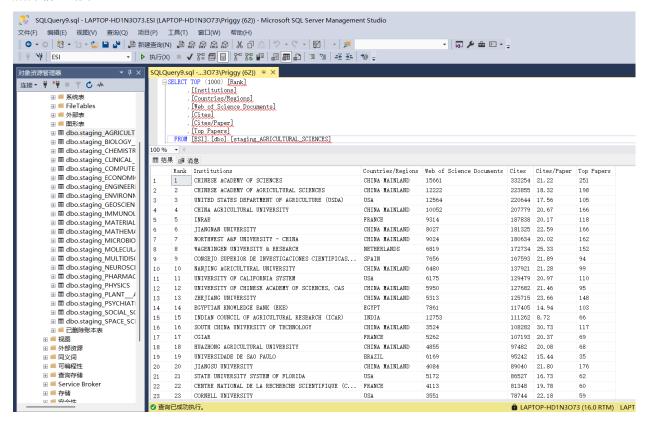
      FIRSTROW=2,
      -- 第 1 行是表头, 从第 2 行开始导

      FIELDQUOTE='"',
      -- 支持带引号的字段

 ROWTERMINATOR='0x0d0a', -- Windows 换行符
 CODEPAGE='65001', -- UTF-8 编码
 TABLOCK
                         -- 提升导入性能
);
```

```
-- 显示导入结果
SELECT '$table' AS TableName, COUNT(*) AS RowsLoaded FROM dbo.$table;
GO
"@ | Set-Content -Encoding UTF8 $tmp # 将 SQL 写入临时文件
# 执行临时 SQL 文件
sqlcmd -S $server -d $database -E -i $tmp
# 删除临时文件, 保持干净
Remove-Item $tmp
}
```

所有表格已成功导入 SSMS:



4. 优化关系型数据,并整理一个合理的schema

为什么要优化?

为了方便查询,优化做的好,5-7题会非常简单

怎么优化?

目前是一个学科一个表格,我们要创建一个总表,整合所有数据

这个总表要增加一列,记录这行数据来源于哪个学科的排名表格:

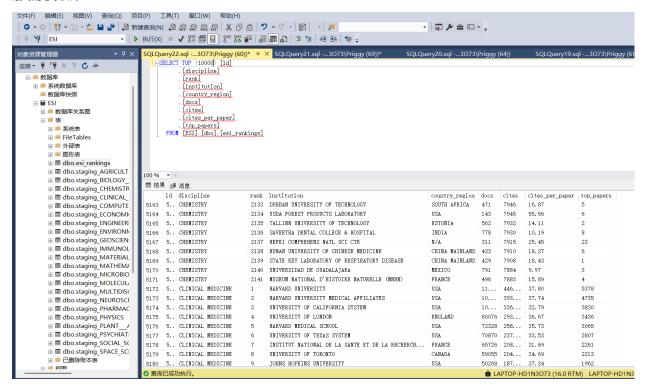
```
USE ESI:
-- 创建一个统一的总表,用来整合所有 staging_* 数据
IF OBJECT_ID('dbo.esi_rankings') IS NOT NULL DROP TABLE dbo.esi_rankings;
CREATE TABLE dbo.esi_rankings(
   id INT IDENTITY(1,1) PRIMARY KEY,
                                        -- 自增主键
   discipline NVARCHAR(128) NOT NULL,
                                        -- 学科名(来自表名)
                                         -- 排名
   [rank] INT NULL,
   institution NVARCHAR(255) NULL,
                                         -- 机构名
   country_region NVARCHAR(128) NULL,
                                         -- 国家或地区
   docs INT NULL,
                                         -- 论文数
   cites INT NULL,
                                         -- 引用数
   cites_per_paper DECIMAL(10,2) NULL,
                                         -- 每篇引用数
   top_papers INT NULL
                                         -- 高被引论文数
);
GO
```

```
-- 遍历所有 staging_* 表,将数据导入 esi_rankings
DECLARE @t SYSNAME, @sql NVARCHAR(MAX), @disc NVARCHAR(128);
-- 获取所有 staging_* 表名
DECLARE cur CURSOR LOCAL FAST_FORWARD FOR
SELECT name FROM sys.tables WHERE name LIKE 'staging\_%' ESCAPE '\';
OPEN cur; FETCH NEXT FROM cur INTO @t;
WHILE @@FETCH_STATUS = 0
BEGIN
    -- 从表名提取学科名,例如 staging_PHYSICS → "PHYSICS"
   SET @disc = REPLACE(SUBSTRING(@t, LEN('staging_')+1, 200), '_', '');
    -- 构造动态 SQL 插入语句
    SET @sq1 = '
      INSERT INTO dbo.esi_rankings(discipline,
[rank], institution, country\_region, docs, cites, cites\_per\_paper, top\_papers)
     SELECT ''' + @disc + ''',
            TRY_CONVERT(INT, [Rank]),
             [Institutions].
             [Countries/Regions],
             TRY_CONVERT(INT,[Web of Science Documents]),
            TRY_CONVERT(INT,[Cites]),
            TRY_CONVERT(DECIMAL(10,2),[Cites/Paper]),
            TRY_CONVERT(INT,[Top Papers])
      FROM dbo.' + QUOTENAME(@t) + '
     WHERE [Institutions] IS NOT NULL AND [Institutions] NOT LIKE ''Copyright%'';
    EXEC(@sq1);
    FETCH NEXT FROM cur INTO @t;
END
CLOSE cur; DEALLOCATE cur;
```

为了方便后续查询,添加学科和机构索引:

```
-- 为后续查询(第5-7题)建立索引
CREATE INDEX IX_esi_rank_disc ON dbo.esi_rankings(discipline); -- 按学科快速筛选
CREATE INDEX IX_esi_rank_inst ON dbo.esi_rankings(institution); -- 按机构快速查询
GO
```

最终的总表如下:



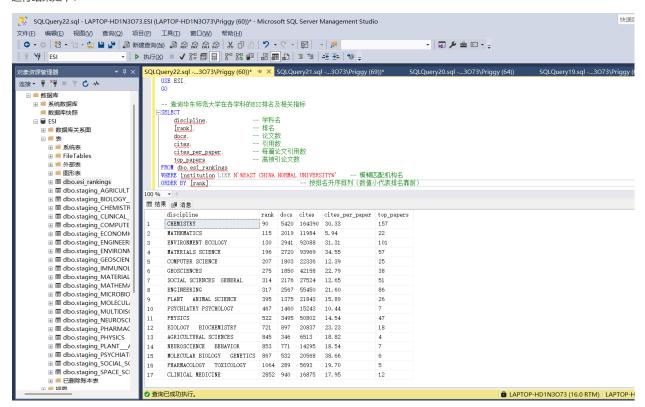
5. 通过写SQL语句,获取华东师范大学在各个学科中的排名

注意,华东师范大学在表格中是英文名称,即 EAST CHINA NORMAL UNIVERSITY

从 dbo.esi_rankings 表格中,选择机构名为 EAST CHINA NORMAL UNIVERSITY 的行,按 rank 从小到大展示

```
USE ESI;
GO
-- 查询华东师范大学在各学科的ESI排名及相关指标
SELECT
   discipline,
                        -- 排名
   [rank],
                        -- 论文数
   docs,
                        -- 引用数
   cites,
                       -- 每篇论文引用数
   cites_per_paper,
                        -- 高被引论文数
   top_papers
FROM dbo.esi_rankings
WHERE institution LIKE N'%EAST CHINA NORMAL UNIVERSITY%' -- 模糊匹配机构名
ORDER BY [rank];
                                     -- 按排名升序排列(数值小代表排名靠前)
```

运行结果如下:



为了便于老师检查, 我想把查询结果输出到一个文件中

把SQL代码保存为 SQLQuery5.sql, 然后在 PowerShell 中运行:

```
sqlcmd -S localhost -d ESI -E -i "D:\ESI\SQLQuery5.sql" -o "D:\ESI\result5.csv" -s "," -W -f 65001
```

文件在附件中供老师检查 (5-7题都有, 为了节省篇幅, 后面不再说明):

	Α	В	С	D	E	F	G	Н	I	J	K	L
1	已将数据周	车上下文更	改为 "ESI'									
2	discipline	rank	docs	cites	cites_per_ı	top_papers						
3							-					
4	CHEMISTF	90	5420	164390	30.33							
5	MATHEMA	115	2019	11984	5.94	22						
6	ENVIRON	130	2941	92088	31.31	101						
7	MATERIAL	196	2720	93969	34.55	57						
8	COMPUTE	207	1803	22336	12.39	25						
9	GEOSCIEN	275	1850	42158	22.79	38						
10	SOCIAL SO	314	2176	27524	12.65	51						
11	ENGINEER	317	2567	55450	21.6							
12	PLANT A	395	1375	21843	15.89	26						
13	PSYCHIAT	467	1460	15243	10.44	7						
14	PHYSICS	522	3495	50802	14.54							
15	BIOLOGY	721	897	20837	23.23	18						
16	AGRICULT	845	346	6513	18.82	4						
17	NEUROSC	853	771	14295	18.54							
18	MOLECUL	867	532	20568	38.66							
19	PHARMA(1064	289	5693	19.7	5						
20	CLINICAL	2852	940	16875	17.95	12						
21												
22	(17 行受影	响)										
23												
24												

6. 通过写SQL语句,获取中国(大陆地区)大学在各个学科中的表现

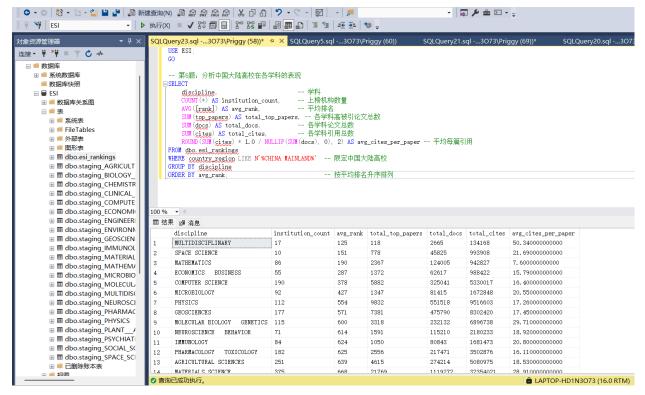
如何限定范围 (中国大陆) ?

限定 country_region 为 CHINA MAINLAND 即可

如何衡量在各个学科中的表现?

看各学科上榜机构数量、平均排名、各学科被引论文总数、各学科论文总数、各学科引用总数、平均每篇引用 这些指标中,平均排名是最权威的,所有按平均排名升序展示

运行结果如下:



为了便于老师检查, 我想把查询结果输出到一个文件中

把SQL代码保存为 SQLQuery6.sql, 然后在 PowerShell 中运行:

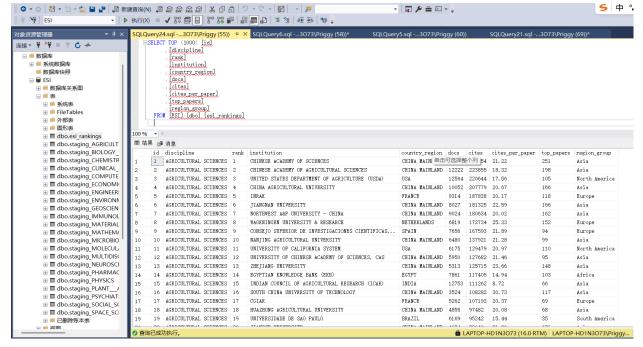
```
sqlcmd -S localhost -d ESI -E -i "D:\ESI\SQLQuery6.sql" -o "D:\ESI\result6.csv" -s "," -W -f 65001
```

7. 通过写SQL语句,分析全球不同区域在各个学科中的表现

全球不同区域需要我们手动划分,按国家或地区填充所属大洲

```
-- 给表添加 region_group 字段
ALTER TABLE dbo.esi_rankings ADD region_group NVARCHAR(64);
-- 按国家或地区填充所属大洲
UPDATE dbo.esi_rankings SET region_group = 'Asia'
WHERE country_region LIKE N'%CHINA%' OR country_region LIKE N'%JAPAN%' OR country_region LIKE N'%KOREA%' OR
country_region LIKE N'%INDIA%';
UPDATE dbo.esi_rankings SET region_group = 'Europe'
WHERE country_region IN (N'UNITED KINGDOM', N'FRANCE', N'GERMANY', N'ITALY', N'SPAIN', N'NETHERLANDS');
UPDATE dbo.esi_rankings SET region_group = 'North America'
WHERE country_region IN (N'USA', N'CANADA', N'MEXICO');
UPDATE dbo.esi_rankings SET region_group = 'South America'
WHERE country_region IN (N'BRAZIL', N'ARGENTINA', N'CHILE');
UPDATE dbo.esi_rankings SET region_group = 'Oceania'
WHERE country_region IN (N'AUSTRALIA', N'NEW ZEALAND');
UPDATE dbo.esi_rankings SET region_group = 'Africa'
WHERE country_region IN (N'EGYPT', N'SOUTH AFRICA');
GO
```

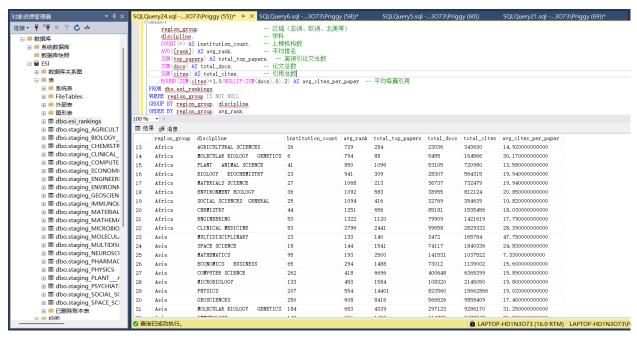
这样,表格右侧就会增加一列 region_group,便于区分全球不同区域:



之后的思路和第6题很相似,只不过 GROUP BY discipline 变为 GROUP BY region_group, discipline,从而将每个区域都展示一遍:

```
USE ESI:
GO
-- 第7题:分析全球不同区域在各学科的表现
   region_group,
                                  -- 区域(亚洲、欧洲、北美等)
   discipline,
                                  -- 学科
   COUNT(*) AS institution_count,
                                  -- 上榜机构数
                                  -- 平均排名
   AVG([rank]) AS avg_rank,
   SUM(top_papers) AS total_top_papers, -- 高被引论文总数
   SUM(docs) AS total_docs, -- 论文总数
   SUM(cites) AS total_cites,
                                  -- 引用总数
   ROUND(SUM(cites)*1.0/NULLIF(SUM(docs),0),2) AS avg_cites_per_paper -- 平均每篇引用
FROM dbo.esi_rankings
WHERE region_group IS NOT NULL
GROUP BY region_group, discipline
ORDER BY region_group, avg_rank;
```

运行结果如下:



为了便于老师检查, 我想把查询结果输出到一个文件中

把SQL代码保存为 SQLQuery7.sql,然后在 PowerShell 中运行:

 $sqlcmd - S \ localhost - d \ ESI - E - i \ "D:\ ESI\ SQLQuery7.sql" - o \ "D:\ ESI\ result7.csv" - s \ "," - W - f \ 65001$